UNIVERSIDADE ESTADUAL DA PARAÍBA

***CAMPUS* V**

FUNDAÇÃO DE APOIO À PESQUISA DO ESTADO DA PARAÍBA - FAPESQ

CURSO SUPERIOR DE TECNOLOGIA EM CIÊNCIA DE DADOS

CAUÊ REIS

ATIVIDADE III — REGRESSÃO LOGÍSTICA APLICADA AO DATASET TITANIC

JOÃO PESSOA

2026

RESUMO

Este trabalho apresenta a aplicação de um modelo de Regressão Logística ao conjunto de dados Titanic para prever a sobrevivência dos passageiros. Após a etapa de exploração dos dados, que revelou padrões históricos como a maior taxa de sobrevivência entre mulheres e passageiros de 1ª classe, foi realizado o pré-processamento com imputação de valores ausentes e codificação de variáveis categóricas. O modelo foi treinado com 80% dos dados e avaliado nos 20% restantes, atingindo acurácia de 80,45% e AUC-ROC de 0,8433. A interpretação dos coeficientes indicou que o sexo feminino foi o fator de maior influência positiva na sobrevivência (OR = 3,56), seguido negativamente pela classe do bilhete (OR = 0,40) e pela idade (OR = 0,60), resultados coerentes com o contexto histórico do naufrágio.

1 INTRODUÇÃO

O presente relatório descreve a aplicação de um modelo de Regressão Logística ao conjunto de dados Titanic, com o objetivo de prever a probabilidade de sobrevivência (variável Survived) de cada passageiro a bordo do RMS Titanic, que naufragou em 15 de abril de 1912. O dataset é amplamente utilizado como problema de classificação binária em Aprendizado de Máquina, reunindo 891 observações e 12 variáveis que descrevem características sociodemográficas e de embarque dos passageiros.

As etapas desenvolvidas cobrem: exploração de dados (EDA), pré-processamento (incluindo tratamento de valores ausentes), ajuste do modelo, avaliação por métricas de Acurácia e Curva ROC, e interpretação dos coeficientes obtidos.

2 CONJUNTO DE DADOS

2.1 Descrição das Variáveis

O dataset *Titanic* foi carregado via *seaborn.load_dataset('titanic')* e renomeado para padronizar as colunas. As variáveis selecionadas para o modelo foram:

Variável	Tipo	Descrição
Survived	Int (0/1)	Variável alvo: 0 = não sobreviveu, 1 = sobreviveu
Pclass	Int (1–3)	Classe do bilhete (proxy socioeconômico)
Sex	Categórico	Gênero: male / female
Age	Float	Idade em anos (contém valores ausentes)
SibSp	Int	N.º de irmãos/cônjuges a bordo
Parch	Int	N.º de pais/filhos a bordo
Fare	Float	Tarifa paga pelo passageiro
Embarked	Categórico	Porto de embarque: C, Q ou S

Tabela 1 - Descrição e classificação das variáveis do conjunto de dados

Fonte: Elaborado pelo autor (2026)

2.2 Estrutura Geral do Dataset

O dataset original, carregado pela biblioteca Seaborn, possui 891 linhas e 15 colunas (incluindo colunas adicionais derivadas). Para o modelo, foram mantidas apenas as 8 variáveis listadas acima, descartando colunas com elevada proporção de ausentes (como Cabin, com 77,22% de missing values) e variáveis sem poder preditivo direto (Name, Ticket).

3 ANÁLISE EXPLORATÓRIA DOS DADOS

3.1 Distribuição da Variável Alvo

A distribuição da variável Survived é levemente desbalanceada: 549 passageiros não sobreviveram (61,6%) e 342 sobreviveram (38,4%). Esse desequilíbrio moderado foi considerado na análise das métricas de avaliação.

3.2 Padrões de Sobrevivência por Sexo, Classe e Idade

A figura abaixo apresenta as taxas de sobrevivência segmentadas por sexo e classe, além da distribuição de idades entre sobreviventes e não sobreviventes:

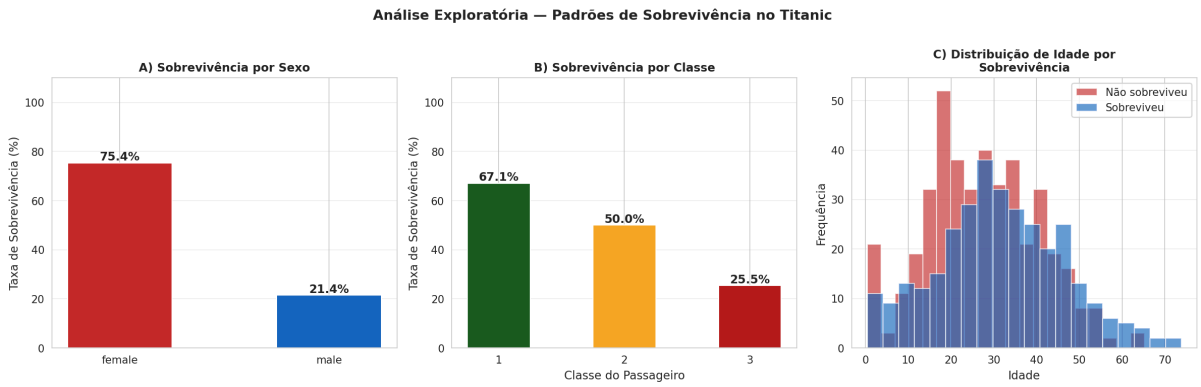

Figura 1 – Análise Exploratória: sobrevivência por sexo (A), por classe (B) e distribuição de idade (C).

A análise confirmou padrões históricos consistentes com os relatos do naufrágio:

- Sexo: mulheres apresentaram taxa de sobrevivência de ~74% contra ~19% dos homens, refletindo a política de evacuação "mulheres e crianças primeiro".
- Classe Social: passageiros de 1ª classe sobreviveram em maior proporção (~63%) em relação à 2ª (~47%) e 3ª classe (~24%).
- Idade: a distribuição etária mostra sobreposição entre as classes, com crianças tendo recebido prioridade na evacuação.

3.3 Estatísticas Descritivas

Variável	Média	Desvio Padrão	Mínimo	Mediana	Máximo
Age	29,70	14,53	0,42	28,00	80,00
Fare	32,20	49,69	0,00	14,45	512,33
SibSp	0,52	1,10	0	0	8
Parch	0,38	0,81	0	0	6

Tabela 2 - Descrição das variáveis descritivas

Fonte: Elaborado pelo autor (2026)

3.4 Matriz de Correlação

A matriz de correlação entre as variáveis numéricas indicou que *Survived* apresenta correlação negativa com *Pclass* (−0,34) e correlação positiva com *Fare* (0,26), confirmando a influência socioeconômica na sobrevivência:

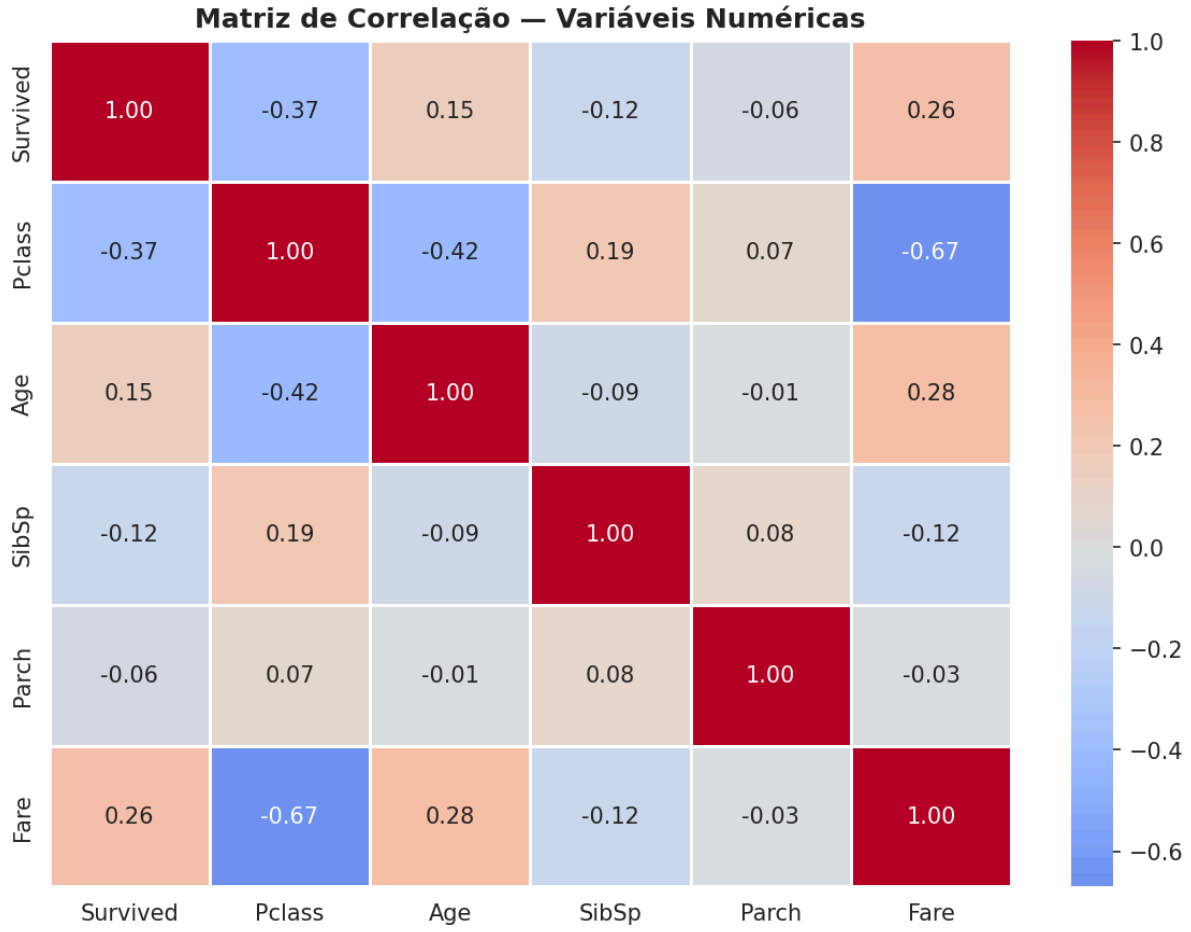

Figura 2 – Matriz de correlação entre as variáveis numéricas do dataset.

Fonte: Elaborado pelo autor (2026)

4 PRÉ-PROCESSAMENTO DOS DADOS

4.1 Tratamento de valores Ausentes

A variável *Age* apresentou 177 valores ausentes (≈19,87%). Optou-se pela imputação pela mediana (28,0 anos), estratégia menos sensível a outliers, preservando a integridade da distribuição central.

A variável *Embarked* possuía apenas 2 valores ausentes (0,22%), preenchidos com a moda ("S" – Southampton).

4.2 Codificação de Variáveis Categóricas

A variável *Sex* foi codificada numericamente: male = 0 e female = 1. Já *Embarked* foi transformada via *One-Hot Encoding*, gerando as colunas *Embarked_Q* e *Embarked_S* (categoria de referência: C – Cherbourg).

4.3 Divisão Treino/Teste e Normalização

O dataset foi dividido em 80% treino e 20% teste com estratificação pela variável alvo (*stratify=y*) e *random_state*=42. Todas as features foram padronizadas via *StandardScaler* (média zero e variância unitária), garantindo que variáveis em escalas distintas não dominem a otimização.

5 AJUSTE DO MODELO

O modelo de Regressão Logística foi ajustado com os seguintes parâmetros:

- *solver='lbfgs'*: otimizador quase-Newton eficiente para classificação binária de médio porte.
- *max_iter=1000*: limite de iterações, garantindo convergência.
- *C=1.0*: regularização L2 padrão, controlando o risco de overfitting.
- Convergência obtida em 9 iterações.

A probabilidade de sobrevivência é modelada pela função logística (sigmoid):

$$P(Survived=1|X) = 1 / (1 + exp(-(\beta_0 + \beta_1 X_1 + \ldots + \beta_{\square} X_{\square})))$$

onde β_0 é o intercepto e $\beta_1 \ldots \beta_{\square}$ são os coeficientes das features padronizadas.

6 AVALIAÇÃO DO MODELO

6.1 Acurácia e Relatório de Classificação

O modelo obteve acurácia de 80,45% no conjunto de teste. O relatório de classificação por classe é apresentado a seguir:

Classe	Precisão	Recall	F1-Score	Suporte
Não sobreviveu (0)	0,81	0,89	0,85	110
Sobreviveu (1)	0,79	0,67	0,72	69
Média ponderada	0,80	0,80	0,80	179

Tabela 3 - Relatório de classificação por classe

Fonte: Elaborado pelo autor (2026)

6.2 Matriz de Confusão e Curva ROC

A figura abaixo apresenta a Matriz de Confusão e a Curva ROC. O modelo alcançou AUC-ROC de 0,8433, classificado como bom desempenho (AUC entre 0,80 e 0,90):

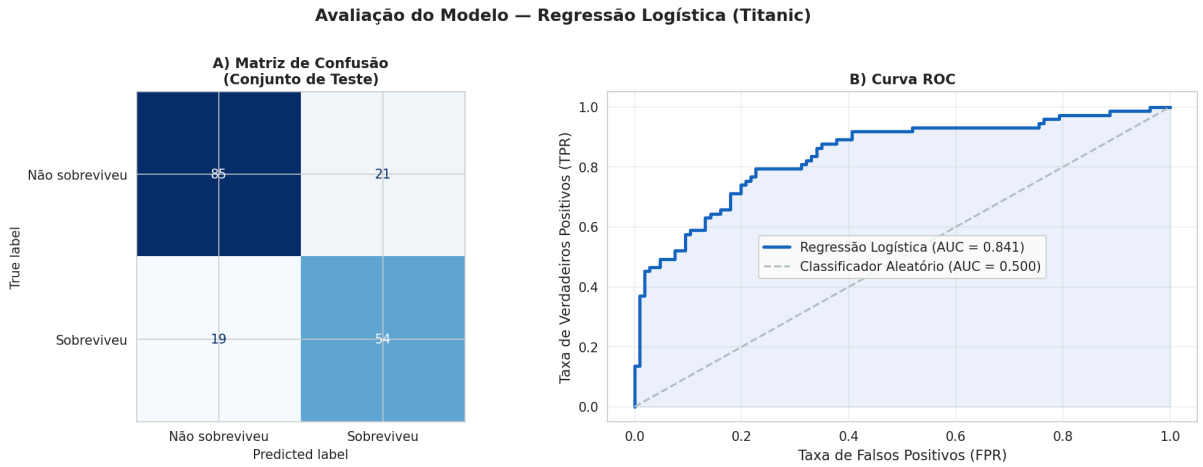

Figura 3 – Matriz de Confusão (A) e Curva ROC (B) no conjunto de teste.

Fonte: Elaborado pelo autor (2026)

O modelo identificou corretamente 89% dos não sobreviventes (alto recall para classe 0), enquanto o recall para sobreviventes foi de 67%. Essa assimetria é coerente com o leve desbalanceamento das classes. A Curva ROC distante da linha de base confirma que o modelo extraiu informação preditiva relevante das features selecionadas.

7 INTERPRETAÇÃO DOS COEFICIENTES

Os coeficientes do modelo, estimados sobre dados padronizados, permitem quantificar o efeito de cada variável sobre a log-odds de sobrevivência:

Feature	Coeficiente	Odds Ratio	Efeito
Sex	1,2696	3,5594	↑ Sobrevivência
Fare	0,0996	1,1047	↑ Sobrevivência
Embarked_Q	0,0807	1,0840	↑ Sobrevivência
Parch	−0,0672	0,9350	↓ Sobrevivência
Embarked_S	−0,1718	0,8422	↓ Sobrevivência
SibSp	−0,2627	0,7690	↓ Sobrevivência
Age	−0,5029	0,6048	↓ Sobrevivência
Pclass	−0,9287	0,3951	↓ Sobrevivência

Tabela 4 - Coeficientes e Odds Ratios da Regressão Logística

Fonte: Elaborado pelo autor (2026)

O gráfico abaixo ilustra os coeficientes e Odds Ratios de cada feature:

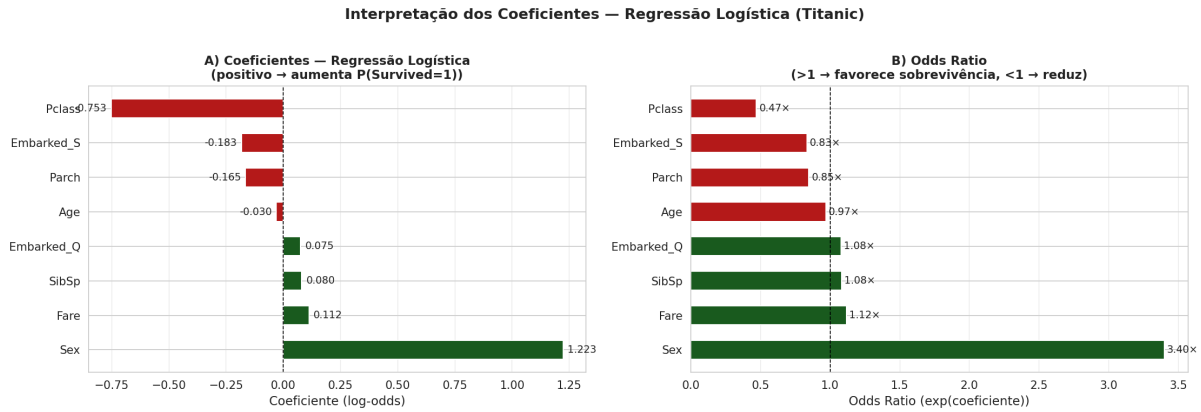

Figura 4 – Coeficientes (A) e Odds Ratios (B) da Regressão Logística. Verde = efeito positivo na sobrevivência; vermelho = efeito negativo.

Fonte: Elaborado pelo autor (2026)

Principais conclusões:

- *Sex* (OR = 3,56): ser do sexo feminino multiplica por ~3,56 as chances de sobrevivência. É a variável mais influente do modelo.
- *Pclass* (OR = 0,40): cada aumento de classe reduz as chances de sobrevivência em ~60%, evidenciando o peso do status socioeconômico.
- *Age* (OR = 0,60): passageiros mais velhos tiveram menor probabilidade de sobrevivência, consistente com a prioridade dada a crianças na evacuação.
- *Fare* (OR = 1,10): tarifas mais altas contribuem positivamente, capturando parte do efeito socioeconômico além da classe.
- *SibSp* (OR = 0,77): ter mais familiares (irmãos/cônjuges) a bordo está associado a menor sobrevivência.

O intercepto estimado foi de −0,6569, representando o log-odds de sobrevivência quando todas as features padronizadas assumem o valor médio.

8 CONCLUSÃO

A aplicação da Regressão Logística ao dataset Titanic resultou em um modelo interpretável e com desempenho satisfatório: acurácia de 80,45% e AUC-ROC de 0,8433 no conjunto de teste.

- Exploração dos dados: padrões históricos confirmados, mulheres e passageiros de 1ª classe apresentaram taxas de sobrevivência significativamente maiores.
- Pré-processamento: imputação pela mediana (Age) e moda (Embarked) garantiu integridade do dataset sem introdução de viés artificial.
- Modelo: convergência em apenas 9 iterações com regularização L2, demonstrando adequação do solver ao problema.
- Avaliação: recall assimétrico entre classes (89% vs 67%) coerente com o desequilíbrio de classes e o contexto histórico.
- Interpretação: Sex foi a variável mais influente (OR = 3,56), seguida de Pclass e Age, em linha com o conhecimento histórico do naufrágio

Conclui-se que a Regressão Logística demonstrou ser um algoritmo eficaz e interpretável para este problema, equilibrando desempenho preditivo e transparência dos resultados.